6. Reinforcement learning (RL)

Motivation. (Voir aussi Hexapawn)

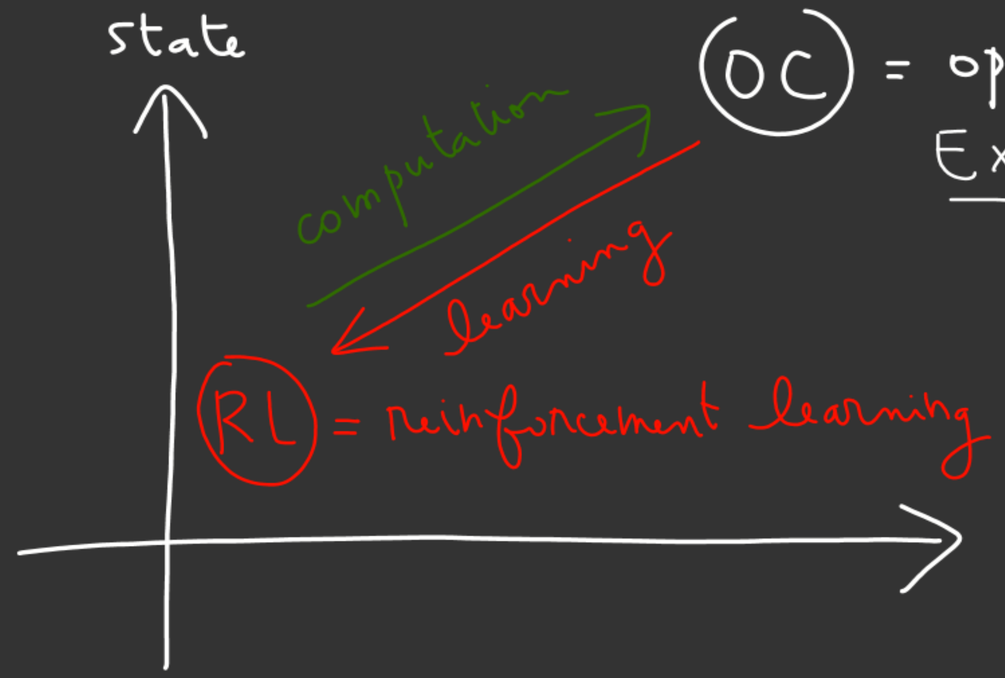

OC = optimal control

Exemple type : maps avec

- carte méconnue : on apprend / enrichit la carte itérativement (= je tombe sur un obstacle → je l'ajoute)
- état = position, avec signal GPS plus ou moins précis

modèle = carte

Model based RL

On se place dans le cadre de la commande optimale discrète sto. :

horizon fini ($t = N$)

le max porte sur $u_0, \dots, u_{N-1}$

$$\begin{cases} E\left(\sum_{t=0}^{N-1} R(x_t, u_t)\right) \longrightarrow \max \\ x_{t+1} = f(x_t, u_t, e_t), \quad t = 0, \dots, N-1 \\ x_0 \text{ connu} \end{cases}$$

reward

temps discret

state $\in \mathbb{R}^n$

processus stochastique à temps discret

($\rightarrow$ MDP = Markov Decision Process)

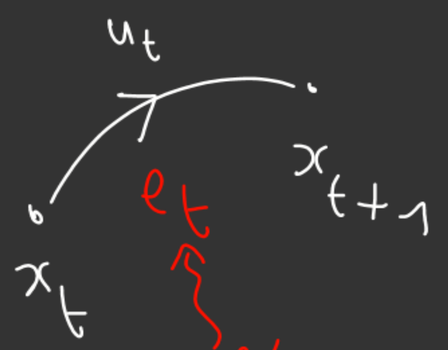

aléa

$$\left(u_t \in U \subset \mathbb{R}^m, \ t = 0, \dots, N-1 \right)$$

control, action

La première approche consiste à apprendre le modèle grâce à un sample / échantillon / épisode (on suppose qu'on sait mesurer état, action et récompense) d'horizon L :

$$(\tilde{x}_0, \dots, \tilde{x}_L), \quad (\tilde{u}_0, \dots, \tilde{u}_{L-1}), \quad (\tilde{r}_0, \dots, \tilde{r}_{L-1})$$

Dans ce cas, on cherche un estimateur de la dynamique discrète, par exemple au sens des moindres carrés (cf. aléa additif : $f(x,u,e) = \bar{f}(x,u) + e \dots$) en posant :

$$\hat{f}(x,u,y) \quad : \quad y \in \mathbb{R}^p, \text{ paramètres de l'estimateur (ex. : NN = neural network)}$$

Et on résout

$$\frac{1}{2}\sum_{t=0}^{L-1} \| \hat{f}(\tilde{x}_t, \tilde{u}_t, y) - \tilde{x}_{t+1} \|^2 \longrightarrow \min \quad (*)$$

$$y \in \mathbb{R}^p$$

(Nonlinear Least Squares – NLSQ)

<u>Remarque</u> : idem pour les rewards si $R(x,u)$ inconnu)

On résout ensuite, la sol. $\bar{y}$ de $(*)$ étant connue, le pb (commande optimale discrète déterministe)

$$\begin{cases} \sum_{t=0}^{N-1} R(x_t, u_t) \longrightarrow \max \\ x_{t+1} = \hat{f}(x_t, u_t, \bar{y}), \ x_0 \text{ connu} \quad (u_t \in U \ldots) \end{cases}$$

Approximate Dynamic Programming (ADP) :

on ne cherche plus à apprendre (au départ) le modèle, mais on se souvient qu'il y a un problème de commande sous-jacent :

$\gamma \in]0,1[$: discount factor, cf. convergence du coût à horizon infini

$$\underbrace{(1-\gamma)}_{\text{normalisation}} \cdot E\left(\sum_{t=0}^{\infty} \gamma^t \cdot R(x_t, u_t)\right) \longrightarrow \max$$

$$x_{t+1} = f(x_t, u_t, e_t), \quad t \geq 0$$

x_0 connu $\quad (u_t \in U \ldots)$

On va associer à ce problème une fonction qui est presque sa "valeur" (= la valeur du coût à l'optimum ; cf. HJB en temps continu).

Déf. (Q-fonction) :

$$Q(x,u) := \max_{u_1,\dots} \left\{ E\left(\sum_{t=0}^{\infty} \gamma^t \cdot R(x_t,u_t)\right) \;\middle|\; \begin{array}{l} x_{t+1} = f(x_t,u_t,e_t),\ t \geq 0 \\ x_0 = x,\ u_0 = u \end{array} \right\}$$

Remarques : i) la (fonction) valeur du problème est

$$V(x) := \max_{u \in U} Q(x,u)$$

ii) l'intérêt de chercher (puis de connaître) Q est de savoir déterminer la (une...) politique optimale en fonction de l'état :

$$u_t \in \arg\max_{u \in U} Q(x_t,u)$$

(ceci fournit une politique $\pi : (x_0,\dots,x_t,u_0,\dots,u_{t-1}) \longrightarrow u_t$ dans ce contexte simple)

<u>Rappel</u> : principe de Bellman en contrôle optimal (continu déterministe) :

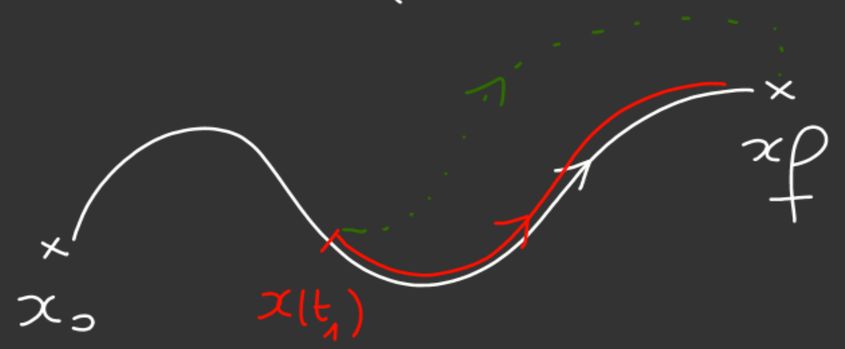

Si la trajectoire $\bar{x} : [0, t_f] \longrightarrow \mathbb{R}^n$ est optimale de x_0 à x_f alors, quel que soit $t_1 \in [0, t_f]$, la trajectoire $\bar{x}_{|[t_1, t_f]} : [t_1, t_f] \longrightarrow \mathbb{R}^n$ est encore optimale entre $\bar{x}(t_1)$ et x_f.

(<u>dém</u> : contradiction sinon, cf. schéma ci-dessus)

Dans notre discret (et à horizon infini), on en déduit de même une relation vérifiée par la fonction Q :

$$Q(x,u) = \max_{u_1,\dots} \left\{ E\left(\sum_{t=0}^{\infty} \gamma^t \cdot R(x_t,u_t)\right) \;\middle|\; \begin{array}{l} x_{t+1} = f(x_t,u_t,e_t),\ t \geq 0 \\ x_0 = x,\ u_0 = u \end{array} \right\}$$

$$= R(x,u) + E\left(\max_{u_1,\dots} \left\{ E\left(\sum_{t=1}^{\infty} \gamma^t \cdot R(x_t,u_t)\right) \;\middle|\; \begin{array}{l} x_{t+1} = f(x_t,u_t,e_t),\ t \geq 1 \\ x_1 = f(x,u,e_0) \end{array} \right\} \right)$$

(Bellman discret : optimalité à partir de $t=1$)

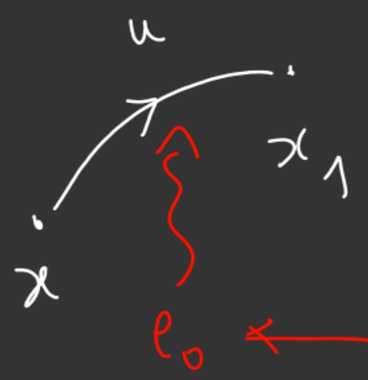

$$= R(x,u) + E\Big(\underbrace{\max_{u'} \max_{u_2,\dots} \Big\{ \gamma\, E\Big(\sum_{t=0}^{\infty} \gamma^t R(x_{t+1}, u_{t+1})\Big) \,\Big|\, \begin{array}{l} x_{t+1} = f(x_t, u_t, e_t),\ t \geq 1 \\ x_1 = f(x, u, e_0), \\ u_1 = u' \end{array} \Big\}}_{Q(f(x,u,e_0),\, u')}\Big)$$

$$= R(x,u) + \gamma\, E\Big(\max_{u'} Q(f(x,u,e_0), u')\Big)$$: équation de pt fixe sur Q

Utilisons le fait que la Q-fonction vérifie cette équ. pour estimer directement cette fonction (= sans remonter jusqu'au modèle). Supposons qu'on dispose d'un estimateur $\hat{Q}(x,u,y)$, $y \in \mathbb{R}^p$ (paramètres); comment l'améliorer itérativement à l'aide d'un nouvel épisode $(\tilde{x}_0, \dots, \tilde{x}_L)$, $(\tilde{u}_0, \dots, \tilde{u}_{L-1})$, $(\tilde{r}_0, \dots, \tilde{r}_{L-1})$? $\left(y_k \xrightarrow{?} y_{k+1} \right)$

$$\hat{Q}(\tilde{x}_t, \tilde{u}_t, y_{k+1}) = \eta \cdot \left[\tilde{r}_t + \gamma \max_{u' \in U} \hat{Q}(\tilde{x}_{t+1}, u', y_k) \right]$$

$$+ (1-\eta) \cdot \hat{Q}(\tilde{x}_t, \tilde{u}_t, y_k), \quad t = 0, \dots, L-1$$

$\eta \in]0,1[$: learning rate

Si $(y_k)_k \longrightarrow \bar{y}$, à la limite on a l'estimateur $\hat{Q}(x,u,\bar{y})$ qu'on utilise selon :

$$u_t \in \arg\max_{u \in U} \hat{Q}(x_t, u, \bar{y}).$$

<u>Remarque</u> : DQL = Deep Q-learning, ie NN pour estimateur $\hat{Q}(x,u,y)$ ($y = W$: poids synaptiques)